검색 품질을 두 단계에서 개선했습니다

입력 질문 → 관련 근거 검색 → 답변 생성. 이번 작업은 검색에 들어가는 청크 품질과 복합 질문의 근거 선택을 각각 개선했습니다.

01

RAG 검색·답변

질문의 두 요구를 분해하고, 각 요구에 맞는 근거 항목을 선택해 답변에 반영

02

청킹·임베딩 입력

자료 없음과 빈 본문 청크를 제거하고, 분할된 청크마다 물질·CAS·항목 문맥 유지

03

같은 기준 평가

화면 사례 3건과 검색 질문 9건으로 전후 결과를 분리해 확인

발표 핵심

복합 질문 누락을 줄이고, 검색 색인에서 불필요한 청크를 제거했습니다.

① RAG: 복합 질문을 항목별로 검색

수정 전

01 질문 전체로 검색

02 상위 결과에 관련 없는 항목 혼입

03 두 요구 중 하나가 빠지거나 다른 대응을 혼동

수정 후

01 질문에서 요청 항목 분해

02 CAS + 항목 메타데이터로 근거 선별

03 항목별 근거를 결합해 두 요구에 답변

화면 사례 3건

두 항목 모두 충족: 수정 전 0/3 → 수정 후 3/3

아세톤(노출·보관), 메탄올(보호구·응급조치), 톨루엔(건강 영향·노출 감소)

※ 사용자가 캡처한 3개 사례의 정성 판정입니다. 전체 질문의 정확도 수치로 해석하지 않습니다.

RAG 답변: 무엇이 달라졌나

물질	질문의 두 요구	수정 전 화면	수정 후 화면
아세톤	노출 경로 + 보관	흡입만 제시, 보관은 답변	흡입·섭취·피부/눈 접촉 + 보관
메탄올	보호구 + 응급조치	보호구 제시, 누출 대응 혼입	보호구 + 피부·눈 응급조치
톨루엔	건강 영향 + 노출 감소	노출 후 조치를 예방으로 제시	건강 영향 + 격리·국소 배기

예외 처리도 보완

아세톤 노출 경로의 “Con” 약어 풀이가 답변에 반영돼도 근거 번호가 누락되면 검증이 실패하던 경우를 수정했습니다. 이는 청킹의 “자료 없음” 청크 문제와 별개의 원인입니다.

② 청킹: 빈 정보 제거와 문맥 보존

수정 전

자료 레코드에 머리글을 한 번 붙인 뒤 전체 텍스트를 1,000자·중첩 100자로 분할

→ 뒤쪽 청크에서 CAS·물질명이 사라질 수 있음

수정 후

자료 없음 항목 제외 → 본문 분할 → 모든 청크에 물질명·CAS·출처·항목 머리글 추가

→ 분할 뒤에도 출처와 대상 물질을 확인 가능

전체 청크	715 → 553	동일 원천 자료 기준
자료 없음	107 → 0	
본문 없는 머리글	66 → 0	
CAS 없는 청크	152 → 0	

검증 결과와 발표 시 표현

9/9 → 9/9

기대 항목 top-5 적중

검색 정확도 상승은 확인되지 않음

107 → 0

“자료 없음” 청크

색인 잡음 제거

152 → 0

CAS 없는 청크

분할 청크 문맥 보존

발표 문장

“RAG는 복합 질문의 항목별 검색과 근거 결합을 개선했습니다. 청킹은 빈 청크를 제거하고 모든 청크에 물질·CAS 문맥을 보존했습니다. 같은 9개 질문의 검색 적중은 9/9로 유지됐으며, 새 색인의 복합 질문 5건은 수동 확인에서 모두 두 항목에 답했습니다.”

근거: datapipeline/reports/chunking_before_after_20261026.md · 화면 캡처 전후 3건 · 2026.10.26. BGE-M3/FAISS는 동일. NIOSH 공통 참고표의 물질별 중복은 남아 있습니다.

구현 흐름: 코드 캡처형 요약

datapipeline/pipeline/pipeline.py

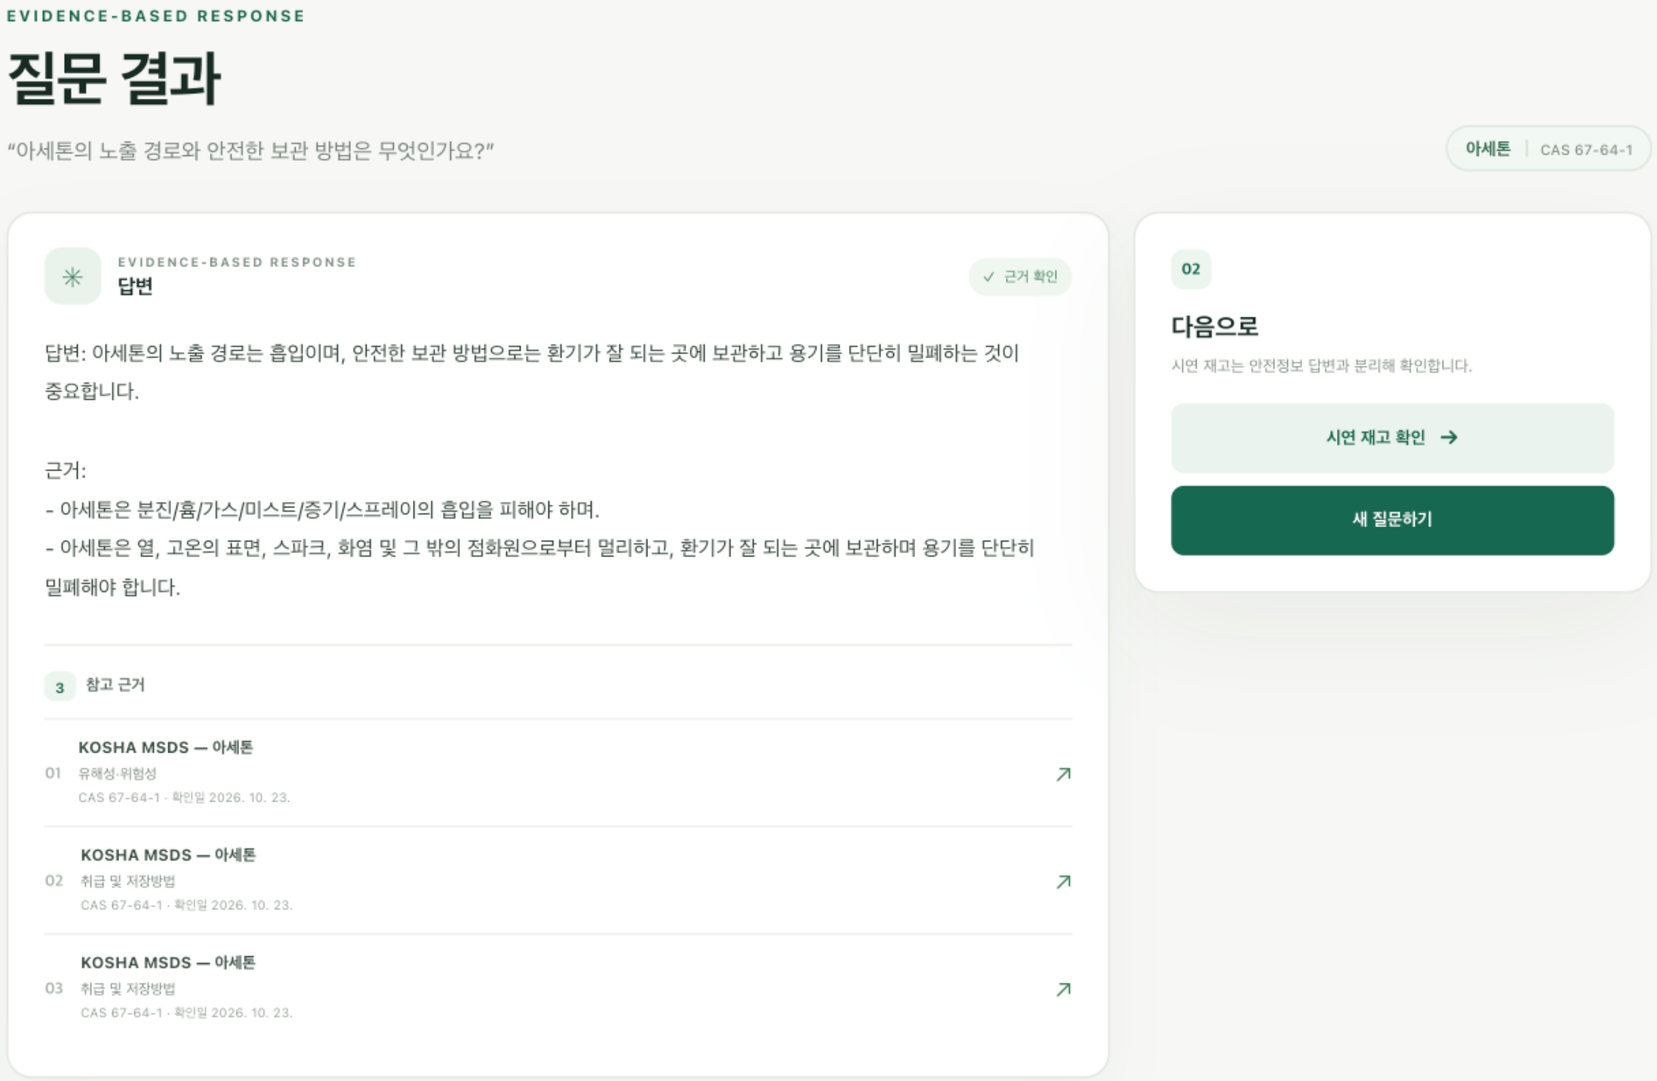
```
if not content or availability == "not_available":
    continue
budget = 1000 - len(header)
for part in splitter.split_text(content):
    docs.append(Document(
        page_content=header + part,
        metadata=metadata.copy()))
```

rag/app/services/rag.py

```
intents = _question_intents(question)
for name, query, section, labels in intents:
    candidates = store.similarity_search(
        query, filter=within_intent)
    groups.append(candidates)
for rank in range(top_k):
    interleave(groups, rank)
```

두 패널은 실제 파일의 핵심 흐름을 짧게 정리한 의사코드입니다. 정확한 구현은 각 파일의 원본 코드를 참고하세요.

아세톤 · 노출 경로 + 보관



전후 판정

수정 전 · 원본 캡처

흡입만 답변하고 섭취·피부/눈 접촉이 빠짐

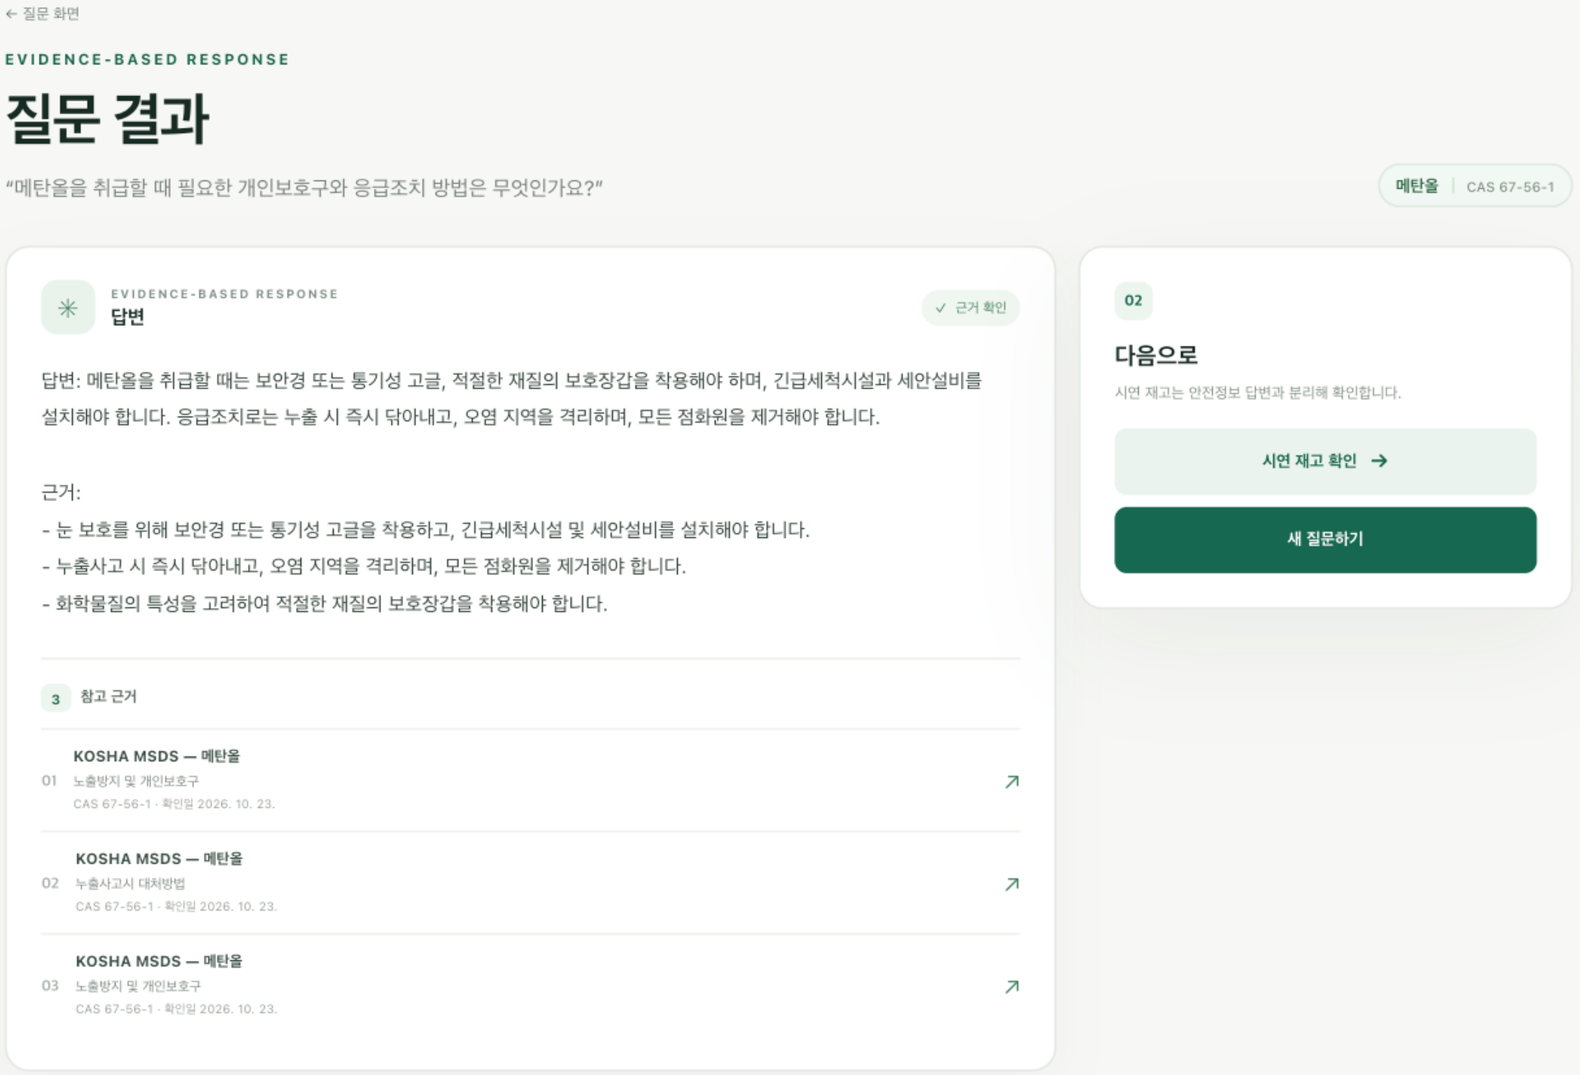
수정 후 · 응답 핵심 요약

흡입·섭취·피부/눈 접촉과 보관을 함께 답변

오른쪽 수정 후 문구는 화면 결과를 발표용으로 요약한 것입니다.

수정 전: 사용자 제공 원본 화면 캡처 · 수정 후: 확인된 답변의 핵심 내용 요약

메탄올 · 보호구 + 응급조치



전후 판정

수정 전 · 원본 캡처

보호구는 제시했지만 누출 대응이 섞임

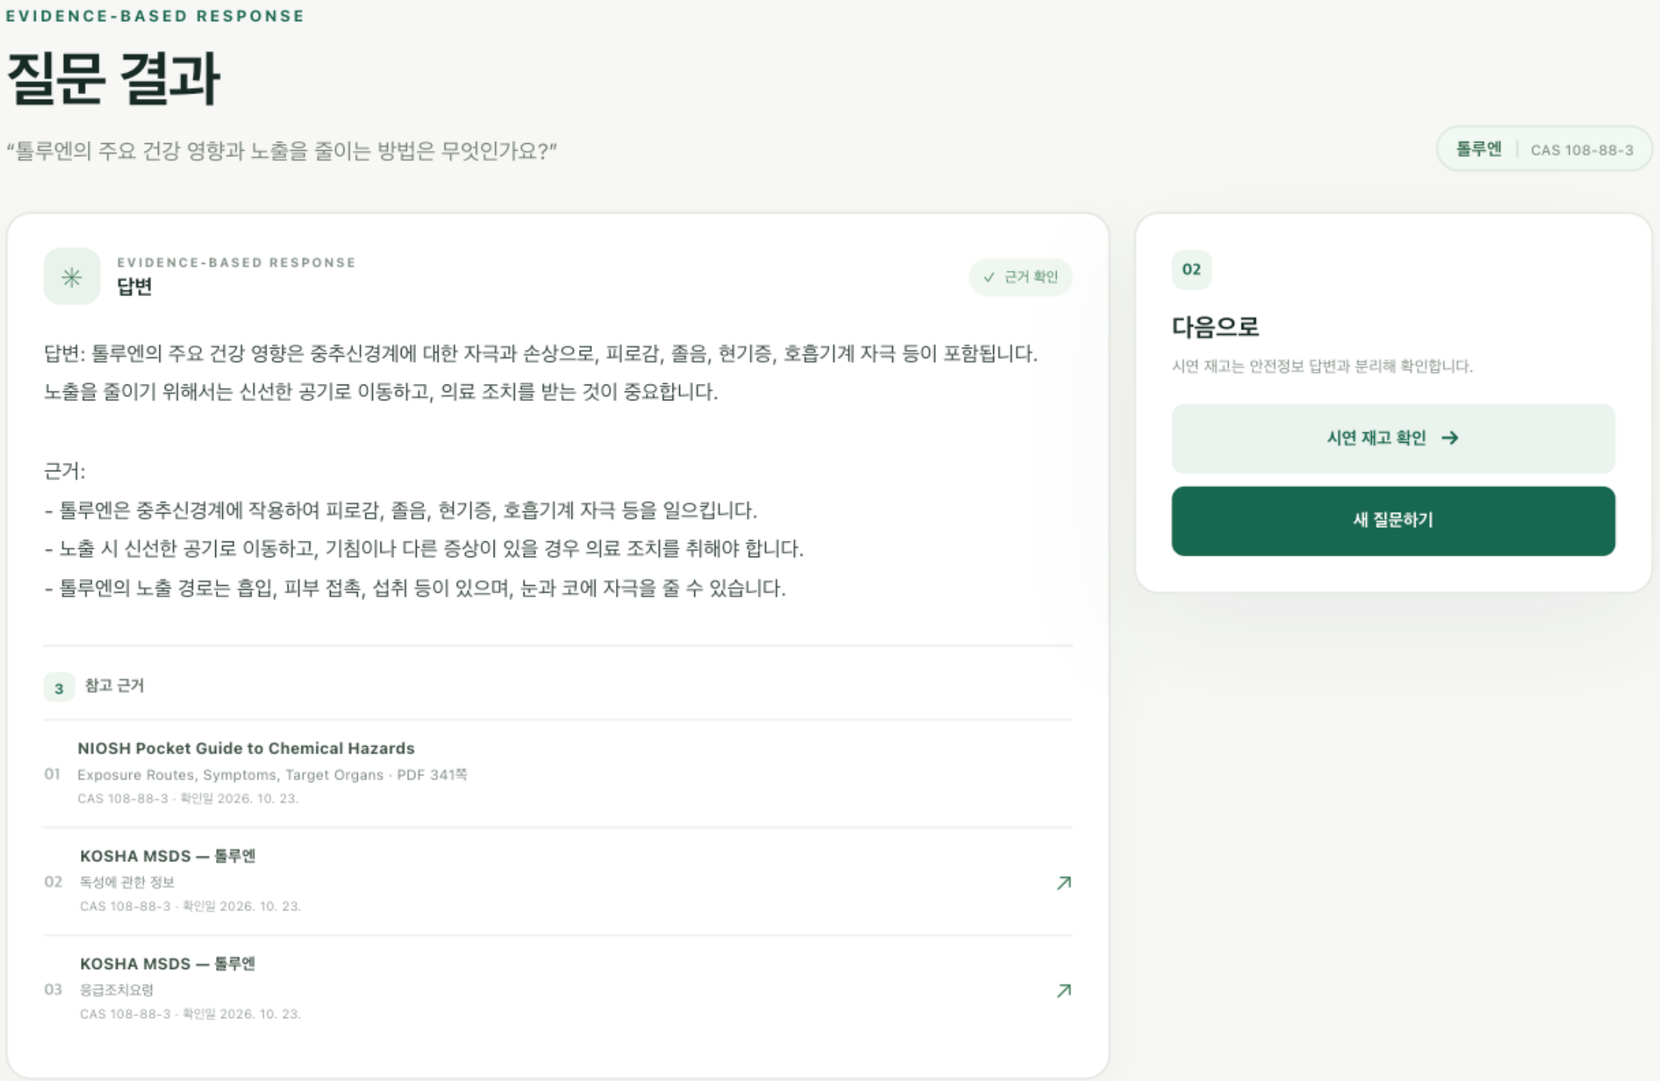
수정 후 · 응답 핵심 요약

보호구와 피부·눈 응급조치를 구분해 답변

오른쪽 수정 후 문구는 화면 결과를 발표용으로 요약한 것입니다.

수정 전: 사용자 제공 원본 화면 캡처 · 수정 후: 확인된 답변의 핵심 내용 요약

톨루엔 · 건강 영향 + 노출 감소



전후 판정

수정 전 · 원본 캡처

노출 후 조치를 노출 예방으로 제시

수정 후 · 응답 핵심 요약

건강 영향과 격리·국소 배기를 함께 답변

오른쪽 수정 후 문구는 화면 결과를 발표용으로 요약한 것입니다.

수정 전: 사용자 제공 원본 화면 캡처 · 수정 후: 확인된 답변의 핵심 내용 요약